



Criação de Agentes Autônomos
Autoria: Thiago Bussola

Indicações de leitura

Prezado aluno (a), selecionamos as referências abaixo visando o aprofundamento das temáticas estudadas na disciplina e a complementação dos seus estudos.

Livros

HUYEN, Chip. *AI Engineering: Building Applications with Foundation Models*. Sebastopol: O'Reilly Media, 2025. 532 p. ISBN 978-1-098-16630-4.

A referência mais próxima do que este módulo faz: engenharia de aplicações sobre modelos prontos, e não treinamento de modelos. Trata avaliação de sistemas com LLM, engenharia de contexto, uso de ferramentas, otimização de custo e latência e arquitetura de aplicações — exatamente as decisões que aparecem nas Unidades 2, 5 e 7.

Leia junto com: Unidade 2 (comparar padrões com métricas, não com opinião), Unidade 5 (contexto como recurso escasso) e Unidade 7 (custo, latência e observabilidade). **Capítulos mais úteis:** os de avaliação de sistemas com IA e os de otimização de inferência.

ALAMMAR, Jay; GROOTENDORST, Maarten. *Hands-On Large Language Models: Language Understanding and Generation*. Sebastopol: O'Reilly Media, 2024. 425 p. ISBN 978-1-098-15096-9.

O livro visual sobre o que existe **por dentro** do modelo que o nosso agente chama. É a melhor leitura para quem quer entender embeddings e busca semântica com profundidade — o mecanismo que a Unidade 4 usa para a memória do OpsPilot — sem precisar de matemática pesada.

Leia junto com: Unidade 4 (embeddings, similaridade, vector store) e Unidade 5 (tokenização e por que contexto custa).

NYGARD, Michael T. *Release It!: Design and Deploy Production-Ready Software*. 2. ed. Raleigh: Pragmatic Bookshelf, 2018. ISBN 978-1-680-50239-8.

A origem dos padrões de resiliência que o módulo implementa: **circuit breaker**, timeouts, bulkheads e antipadrões de estabilidade. Escrito antes da era dos agentes, e por isso mesmo esclarecedor — mostra que os freios da Unidade 7 não são invenção da IA, são engenharia de sistemas distribuídos aplicada a um cliente novo.

Leia junto com: Unidade 3 (timeout e retry na fronteira externa), Unidade 6 (retry e fallback) e Unidade 7 (circuit breaker e degradação controlada).

RUSSELL, Stuart; NORVIG, Peter. *Artificial Intelligence: A Modern Approach*. 4. ed. Hoboken: Pearson, 2021. ISBN 978-0-134-61099-3. (complementar)

O capítulo 2 — "Intelligent Agents" — é a fundação conceitual de tudo: agente, ambiente, percepção, ação, função de utilidade e os tipos de agente. Serve para o aluno perceber que "agente" não nasceu com os LLMs; o que mudou foi o motor de decisão.

Leia junto com: Unidade 1 (o que é agente, o que é harness) e Unidade 9 (sistemas multiagente).

Artigos

YAO, Shunyu et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: International Conference on Learning Representations (ICLR), 2023. arXiv:2210.03629.

O artigo que fundamenta o primeiro padrão da Unidade 2. Mostra por que intercalar raciocínio e ação supera tanto o raciocínio puro (que alucina fatos quando não sabe) quanto a ação cega — e apresenta a *reasoning trace* que o módulo transforma em estrutura tipada e, na Unidade 7, em trilha de auditoria.

Conecta com: Unidade 2 (implementação do ReAct) e Unidade 7 (o trace como registro forense).

WANG, Lei et al. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models. In: Annual Meeting of the Association for Computational Linguistics (ACL), 2023. arXiv:2305.04091.

A linhagem do Plan-and-Execute: primeiro decompor o objetivo em plano, depois executar. Ler o artigo ajuda a entender por que o plano melhora a coerência global e, ao mesmo tempo, por que ele envelhece — o problema que o replanner resolve e que a Unidade 2 demonstra desligando o replanner de propósito.

Conecta com: Unidade 2 (planner/executor/replanner) e Unidade 6 (o roteador escolhendo a estratégia).

SHINN, Noah et al. Reflexion: Language Agents with Verbal Reinforcement Learning. In: Conference on Neural Information Processing Systems (NeurIPS), 2023. arXiv:2303.11366.

A base do terceiro padrão: o agente avalia a própria saída em linguagem natural e usa essa crítica como contexto da nova tentativa. Complemento direto: MADAAN, Aman et al. **Self-Refine: Iterative Refinement with Self-Feedback** (NeurIPS, 2023; arXiv:2303.17651), que trata o mesmo ciclo pelo ângulo do refinamento iterativo.

Conecta com: Unidade 2 (a camada *withReflection*, com crítico e teto de iterações) e Unidade 4 (o mesmo mecanismo reaproveitado como aprendizado de memória).

LIU, Nelson F. et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, v. 12, 2024. arXiv:2307.03172.

A evidência empírica por trás da regra "contexto é orçamento": modelos recuperam bem a informação no começo e no fim do contexto, e degradam no meio. É o artigo que justifica, com dado, por que a Unidade 5 corta, resume e prioriza em vez de simplesmente aumentar a janela.

Conecta com: Unidade 5 (context rot, orçamento por seção, sumarização em rolo).

PARK, Joon Sung et al. Generative Agents: Interactive Simulacra of Human Behavior. In: *ACM Symposium on User Interface Software and Technology (UIST)*, 2023. arXiv:2304.03442. *(complementar)*

O trabalho que popularizou a arquitetura de memória de agentes com três peças — observação, **reflexão** (destilar memórias em insights de longo prazo) e planejamento. É exatamente o desenho que a Unidade 4 implementa em escala reduzida no refletor do OpsPilot.

Conecta com: Unidade 4 (memória semântica e refletor) e Unidade 9 (agentes que coordenam por estado compartilhado).

Documentação técnica de referência

Não são leitura acadêmica, mas são as fontes que o módulo usa e que mudam rápido — vale conferir a versão vigente antes de cada unidade:

- **Model Context Protocol** — especificação e diretório de servidores: modelcontextprotocol.io (Unidade 3).
- **LangGraph (JS)** — grafos de execução, [interrupt](https://langchain-ai.github.io/langgraphjs), checkpoints: langchain-ai.github.io/langgraphjs (Unidades 2, 6, 7 e 9).
- **GitHub Spec Kit** — o framework de spec-driven development adotado a partir da Unidade 2: github.com/github/spec-kit.
- **GitHub Copilot — customização** (instructions, prompt files, chat modes) e **auto-aprovação de terminal**: documentação do VS Code e do Copilot (Unidade 1).
- **Anthropic — Building Effective Agents** (dez./2024): ensaio de engenharia que defende começar pelo mais simples e só então compor padrões; boa contraprova para o entusiasmo com multiagente da Unidade 9.

