



**Arquitetura de Sistemas com IA**  
**Autoria: José Ahirton Batista Lopes Filho**

## Indicações de leitura

Prezado(a) aluno(a), selecionamos as referências abaixo visando o aprofundamento das temáticas estudadas na disciplina. As indicações cobrem os papers acadêmicos que fundamentam os padrões de arquitetura apresentados, relatórios de mercado e documentação técnica de provedores de nuvem citados ao longo do curso, além de recursos audiovisuais gratuitos para aprofundamento contínuo.

### 1. Referências Científicas e Acadêmicas

---

Artigos peer-reviewed e papers técnicos que fundamentam os padrões de arquitetura ensinados na disciplina. Todos os artigos disponíveis no arXiv podem ser acessados gratuitamente em [arxiv.org](https://arxiv.org).

#### **Indicação 1: Yao, S. et al. "ReAct: Synergizing Reasoning and Acting in Language Models." ICLR 2023.**

Paper que introduziu o padrão ReAct, combinando raciocínio (Thought) e ação (Action) num loop iterativo com observação do resultado antes da próxima decisão - hoje presente, sob nomes diferentes, na maioria dos frameworks de agentes.

*Relevância no curso: Módulo 2.2 (O Loop ReAct) - fundamenta o padrão Pensamento-Ação-Observação que estrutura o loop do agente TrialForge.*

#### **Indicação 2: Shinn, N. et al. "Reflexion: Language Agents with Verbal Reinforcement Learning." NeurIPS 2023.**

Formaliza o padrão de reflexão/autocrítica verbal como forma de reforço sem re-treinar o modelo - o agente critica sua própria saída em linguagem natural antes de entregar a resposta final.

*Relevância no curso: Módulo 2.3 (Reflexão e Autocrítica) - fundamenta o padrão de autocrítica verbal sem re-treinamento usado no protótipo de reflexão do TrialForge.*

#### **Indicação 3: Wang, Z. et al. "InformGen: An AI Copilot for Accurate and Compliant Clinical Research Consent Document Generation." arXiv:2504.00934, 2025 (pesquisadores da University of Illinois Urbana-Champaign; versão revisada publicada na Journal of the American Medical Informatics Association, 2026).**

Copiloto de IA que gera Termos de Consentimento Livre e Esclarecido a partir do protocolo de um estudo clínico: extrai e estrutura o protocolo em blocos, e gera o conteúdo de cada seção via busca e redação automática (RAG), com avaliação de compliance regulatório e acurácia factual.

*Relevância no curso: Módulo 2.2 (O Loop ReAct) - mesmo problema de geração de ICF a partir de protocolo clínico do case TrialForge, tratado como pesquisa acadêmica publicada.*

**Indicação 4: Brewer, E. "Towards Robust Distributed Systems" (Teorema CAP, PODC 2000); Gilbert, S.; Lynch, N. "Brewer's Conjecture and the Feasibility of Consistent, Available, Partition-Tolerant Web Services." ACM SIGACT News, 2002.**

O Teorema CAP, proposto por Brewer em 2000 e formalmente demonstrado por Gilbert e Lynch em 2002, estabelece que um sistema distribuído não pode garantir Consistência, Disponibilidade e Tolerância a Partição simultaneamente - base para decidir como um sistema de agentes reage a falha de nó.

*Relevância no curso: Módulo 3.4 (Desafios Distribuídos) - fundamenta o Teorema CAP usado para explicar os trade-offs de consistência e disponibilidade da arquitetura multi-agente do TrialForge.*

**Indicação 5: Garcia-Molina, H.; Salem, K. "Sagas." ACM SIGMOD, 1987.**

Paper original que descreve o padrão Saga - uma sequência de transações locais com passos de compensação explícitos para desfazer o que já foi feito, em vez de uma transação distribuída tradicional.

*Relevância no curso: Módulo 3.4 (Desafios Distribuídos) - fundamenta o padrão Saga de compensação usado no fluxo distribuído do TrialForge.*

**Indicação 6: Chang, E. Y.; Geng, L. "SagaLLM: Context Management, Validation, and Transaction Guarantees for Multi-Agent LLM Planning." arXiv:2503.11951, 2025 (também publicado em PVLDB, vol. 18).**

Estende o padrão Saga clássico (Garcia-Molina & Salem, 1987) para sistemas multiagente baseados em LLM, propondo mecanismos de gerenciamento de contexto, validação e garantias transacionais para planejamento distribuído entre agentes de IA generativa.

*Relevância no curso: Módulo 3.4 (Desafios Distribuídos) - conecta o padrão Saga clássico à orquestração moderna de agentes de LLM, o mesmo problema de compensação tratado no TrialForge.*

**Indicação 7: Lewis, P. et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." NeurIPS 2020.**

O paper seminal, da Meta AI, que introduziu formalmente o RAG - combinar um modelo generativo com um mecanismo de busca em uma base de conhecimento externa antes de gerar a resposta.

*Relevância no curso: Módulo 4.1 (RAG) - fundamenta o padrão de geração aumentada por recuperação usado na base regulatória consultada pelos agentes do TrialForge.*

**Indicação 8: Cormack, G.; Clarke, C.; Büttcher, S. "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods." SIGIR, 2009.**

Demonstra que combinar rankings de busca por um método simples de fusão recíproca (RRF) supera métodos de aprendizado de ranking muito mais sofisticados - base técnica da busca híbrida (vetorial + esparsa).

*Relevância no curso: Módulo 4.1 (RAG) - fundamenta o método de fusão de ranques (RRF) usado na busca híbrida do TrialForge.*

**Indicação 9: Jiang, Z. et al. "Active Retrieval Augmented Generation" (FLARE), 2023; Asai, A. et al. "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection." ICLR 2024.**

Dois papers que formalizaram a busca iterativa e autoavaliada - o sistema decide, a cada passo, se já tem informação suficiente para responder ou se precisa buscar mais, em vez de fazer uma única consulta fixa.

*Relevância no curso: Módulo 4.1 (RAG) - fundamenta as variações avançadas de RAG (recuperação ativa, autocrítica) apresentadas como evolução do RAG básico do TrialForge.*

**Indicação 10: Singh, A. et al. "Agentic Retrieval-Augmented Generation: A Survey." arXiv:2501.09136, 2025.**

Survey que consolidou o termo "Agentic RAG" como forma padrão de descrever sistemas de RAG em que o próprio agente decide quando, onde e quantas vezes buscar - não uma única recuperação fixa.

*Relevância no curso: Módulo 4.1 (RAG) - fundamenta o padrão Agentic RAG, em que o próprio agente decide quando e o que recuperar, discutido no TrialForge.*

**Indicação 11: "RouteLLM: Learning to Route LLMs with Preference Data." ICLR 2025 (pesquisadores de UC Berkeley, em parceria com Anyscale e Canva).**

Framework de código aberto que aprende a rotear cada consulta entre um modelo caro e um barato, atingindo a maior parte da performance do modelo caro usando-o em apenas uma fração das chamadas.

*Relevância no curso: Módulo 4.2 (Roteamento Inteligente) - fundamenta o roteamento aprendido entre modelos de custo diferente, base do gateway de roteamento do TrialForge.*

**Indicação 12: "GPTCache" (Fu Bang, Zilliz). Apresentado no workshop NLP-OSS, 2023.**

Projeto de código aberto de cache semântico para LLMs - armazena embeddings de consultas anteriores e reaproveita a resposta quando uma nova consulta é semanticamente equivalente, não apenas idêntica caractere a caractere.

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - fundamenta o cache semântico usado para evitar chamadas repetidas de modelo no TrialForge.*

**Indicação 13: "Prompt Cache: Modular Attention Reuse for Low-Latency Inference." Pesquisadores de Yale em colaboração com o Google. MLSys, 2024.**

Técnica que reaproveita o estado de atenção computado para partes reutilizáveis do prompt (como instruções de sistema), reduzindo latência sem precisar recomputar tudo do zero a cada chamada.

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - técnica complementar de reuso de atenção para reduzir latência, contexto técnico do cache do TrialForge.*

**Indicação 14: Madras, D.; Pitassi, T.; Zemel, R. "Predict Responsibly: Improving Fairness and Accuracy by Learning to Defer." NeurIPS 2018.**

Formaliza matematicamente quando um sistema de decisão automatizado deve "aprender a adiar" para um humano em vez de decidir sozinho - base acadêmica do conceito de limiar de confiança calibrado.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - fundamenta a ideia de adiar decisões de alto risco a um revisor humano, base conceitual do Approval Gate do TrialForge.*

**Indicação 15: Stevens, W.; Myers, G.; Constantine, L. "Structured Design." IBM Systems Journal, 1974.**

Paper clássico de engenharia de software que formaliza acoplamento e coesão como métricas de qualidade de design - base conceitual, décadas antes da IA generativa, do princípio de desacoplamento aplicado à arquitetura de agentes em escala.

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - fundamenta os princípios clássicos de acoplamento e coesão aplicados à arquitetura de microsserviços do TrialForge.*

### **Indicação 16: Chen, L.; Zaharia, M.; Zou, J. Estudo sobre variação de acurácia do GPT-4 ao longo do tempo, 2023 (pesquisadores de Stanford e Berkeley).**

Mediu a acurácia do GPT-4 numa tarefa de identificar números primos caindo de 84% em março de 2023 para 51% em junho do mesmo ano - evidência empírica de que a qualidade de um modelo de terceiros pode variar sem aviso, motivando monitoramento contínuo de qualidade, não só de erro técnico.

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - demonstra empiricamente a variação de acurácia de modelos ao longo do tempo, motivo real do monitoramento contínuo do TrialForge.*

### **Indicação 17: Chen, L.; Zaharia, M.; Zou, J. "FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance." TMLR, 2024.**

Formaliza a cascata de modelos - chamar primeiro um modelo barato e escalar para um mais caro só quando necessário - como estratégia comprovada de redução de custo sem perda relevante de qualidade.

*Relevância no curso: Módulo 5.4 (Model Tiering) - fundamenta a cascata de modelos por custo que estrutura o model tiering do TrialForge.*

### **Indicação 18: Chen, L.; Zaharia, M.; Zou, J. "How Is ChatGPT's Behavior Changing over Time?" arXiv:2307.09009, 2023.**

Mediu a acurácia do GPT-4 em identificar números primos caindo de 84% (março de 2023) para 51% (junho de 2023) - mesma API, mesma latência, comportamento diferente por baixo do capô, evidência de que sinais de infraestrutura sozinhos não capturam deriva de qualidade do modelo.

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - evidência empírica de deriva de comportamento do modelo ao longo do tempo, mesmo argumento usado para justificar observabilidade contínua no TrialForge.*

## **2. Referências de Mercado e Relatórios da Indústria**

---

Relatórios de analistas, documentação técnica de provedores de nuvem, press releases e normas regulatórias citados ao longo do curso.

### **Relatório 1: RAND Corporation. "Why AI Projects Fail." PTA2680-1, 2025 (James Ryseff e Anu Narayanan).**

Aponta que mais de 80% dos projetos de IA corporativos falham em entregar o valor de negócio prometido - o dobro da taxa de falha de projetos de software convencional, citando estimativas de terceiros para o número, não uma medição própria da RAND.

*Relevância no curso: Módulo 1.1 (Fundamentos de Arquitetura AI-First) - dado empírico usado para embasar a taxa real de fracasso de projetos de IA que abre a disciplina.*

## **Relatório 2: S&P Global Market Intelligence. "Voice of the Enterprise: AI & Machine Learning, Use Cases 2025." 2025.**

Pesquisa com 1.006 profissionais de TI e negócio na América do Norte e Europa. Mostrou que 42% das empresas abandonaram a maioria de suas iniciativas de IA em 2025 - alta de 17% no ano anterior - descartando em média 46% dos protótipos antes de chegarem à produção.

*Relevância no curso: Módulo 1.1 (Fundamentos de Arquitetura AI-First) - pesquisa de mercado usada para embasar o percentual de empresas que já adotam IA generativa citado na abertura do curso.*

## **Relatório 3: Gartner. "Gartner Predicts Over 40% of Agentic AI Projects Will Be Canceled by End of 2027." Press release, 25 de junho de 2025.**

Previsão de que mais de 40% dos projetos de IA agêntica serão cancelados até o fim de 2027, por custo crescente, valor de negócio pouco claro ou controles de risco inadequados.

*Relevância no curso: Módulo 1.1 (Fundamentos de Arquitetura AI-First) - projeção de mercado usada para embasar o risco de abandono de projetos de IA agêntica discutido na abertura do curso.*

## **Relatório 4: Amazon Web Services. "Generative AI Lens" (AWS Well-Architected Framework, 2025) e "Agentic AI Lens" (2026).**

Extensão do Well-Architected Framework da AWS para IA generativa e agentic, cobrindo 8 cenários reais de arquitetura - da entrada à orquestração de agentes, observabilidade e governança.

*Relevância no curso: Módulo 1.2 (O Diagrama de Referência) - referência oficial da AWS para a arquitetura de referência (Gateway-Orquestrador-Modelo-Gate Humano) apresentada no módulo.*

## **Relatório 5: Google Cloud. "Reference Architectures for Generative AI with RAG." Cloud Architecture Center, 2025.**

Família de arquiteturas de referência oficiais do Google Cloud para RAG, organizadas em dois subsistemas - Ingestão (dados → embeddings → índice vetorial) e Serving (frontend → backend → orquestração de agente).

*Relevância no curso: Módulo 1.2 (O Diagrama de Referência) - referência oficial do Google Cloud para o mesmo padrão de arquitetura de referência com RAG apresentado no módulo.*

## **Relatório 6: Microsoft. "Baseline Microsoft Foundry Chat Reference Architecture." Azure Architecture Center, 2026.**

Arquitetura de referência "production-ready" para chat com IA generativa - Foundry Agent Service, identidades gerenciadas, subnets e endpoints privados.

*Relevância no curso: Módulo 1.2 (O Diagrama de Referência) - referência oficial da Microsoft para o mesmo padrão de arquitetura de referência, confirmando a convergência entre os 3 principais provedores de nuvem.*

## **Relatório 7: Anthropic. "Model Context Protocol" (MCP). Novembro de 2024.**

Padrão aberto que define um formato único para um agente descrever ferramentas, receber contexto e devolver resultados - permite que qualquer ferramenta nova compatível se integre sem exigir uma sintaxe própria.

*Relevância no curso: Módulo 2.4 (Ferramentas e Protocolos) - especificação oficial do Model Context Protocol, o protocolo-padrão de ferramentas apresentado no módulo.*

## **Relatório 8: Google. "Agent2Agent Protocol" (A2A). Abril de 2025; hoje sob a Linux Foundation.**

Protocolo aberto para comunicação entre agentes de diferentes fornecedores, anunciado com apoio de mais de 50 parceiros de tecnologia - o equivalente ao MCP, só que entre agentes, não entre agente e ferramenta.

*Relevância no curso: Módulo 3.1 (Por Que Múltiplos Agentes) - especificação oficial do Agent2Agent Protocol, citado como contraponto ao MCP na distinção entre comunicação agente-ferramenta e agente-agente.*

## **Relatório 9: Microsoft Research. "AutoGen." 2023.**

Framework de pesquisa que implementa o padrão Group Chat com um componente central, o GroupChatManager, coordenando múltiplos agentes conversando entre si.

*Relevância no curso: Módulo 3.3 (Hierarchical, Group Chat e Handoff) - framework de origem do padrão Group Chat apresentado no módulo.*

## **Relatório 10: OpenAI. "Swarm" (outubro de 2024), evoluído para "Agents SDK" (março de 2025).**

Framework leve da OpenAI focado no padrão Handoff - transferência completa de controle entre agentes especializados, com contexto acumulado.

*Relevância no curso: Módulo 3.3 (Hierarchical, Group Chat e Handoff) - framework de origem do padrão Handoff apresentado no módulo.*

**Relatório 11: Gartner. “Multiagent Systems” (artigo online; alta de 1.445% nas consultas sobre sistemas multi-agente entre Q1/2024 e Q2/2025) e “Gartner Predicts 40% of Enterprise Apps Will Feature Task-Specific AI Agents by 2026, Up from Less Than 5% in 2025” (press release, 26 de agosto de 2025).**

Dois dados da mesma consultoria, usados em conjunto para justificar por que sistemas multiagente deixaram de ser tema acadêmico e viraram prioridade de arquitetura corporativa: o salto na demanda por orientação sobre arquitetura multiagente e a projeção de adoção de agentes especializados por tarefa em aplicações corporativas.

*Relevância no curso: Módulo 3.3 (Hierarchical, Group Chat e Handoff) - dado de mercado usado para embasar o crescimento de interesse em sistemas multiagente citado na abertura do módulo.*

**Relatório 12: Lucidworks / Forrester. Estudo de caso B2B de busca híbrida.**

Mediu, numa organização composta de design, manufatura e varejo (750 milhões de dólares em receita de e-commerce), o ganho de combinar busca exata com busca semântica: retorno de 391% sobre investimento em três anos.

*Relevância no curso: Módulo 4.1 (RAG) - estudo de caso usado para embasar o ganho real de busca híbrida (lexical + semântica) apresentado no módulo.*

**Relatório 13: Salesforce. Estudo de caso Fisher & Paykel (fabricante de eletrodomésticos) com o Agentforce.**

Atendimento ao cliente com busca simultânea na base de conhecimento de produtos e em dados de CRM: atendimento 50% mais rápido e projeção de mais que dobrar a taxa de autoatendimento, superando 65%.

*Relevância no curso: Módulo 4.1 (RAG) - estudo de caso real de RAG aplicado a atendimento ao cliente, usado como exemplo de produção no módulo.*

**Relatório 14: OpenAI. System Card do GPT-5. 7 de agosto de 2025.**

Descreve a arquitetura do GPT-5 como um roteador em tempo real entre um modelo rápido (gpt-5-main) e um modelo de raciocínio profundo (gpt-5-thinking), retreinado continuamente com sinais reais de uso - troca manual de modelo, taxa de preferência entre respostas, correção medida.

*Relevância no curso: Módulo 4.2 (Roteamento Inteligente) - documentação oficial do roteamento nativo entre modelos de tamanhos diferentes, citada como evolução de mercado do padrão de roteamento apresentado no módulo.*

### **Relatório 15: Nielsen, J. "Response Times: The 3 Important Limits." Nielsen Norman Group, 1993.**

Referência clássica de usabilidade que estabelece os limiares de tempo de resposta percebidos pelo usuário - até 0,1s parece instantâneo, até 1s mantém o fluxo de pensamento, a partir de 10s a atenção se perde.

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - referência clássica de UX para os limiares de tempo de resposta usados para justificar streaming e cache no módulo.*

### **Relatório 16: Rohit Chatter (Chief Software Architect, Walmart Global Tech). Fireside chat "Semantic Caching at Scale", 2024 (organizado pela Portkey.ai).**

Relato público sobre o sistema de cache semântico do Walmart, usando similaridade de cosseno: taxa de acerto de cerca de 50% em consultas de cauda longa, muito acima da expectativa inicial da equipe (10-20%).

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - relato real de produção sobre cache semântico em escala (Walmart Global Tech), usado como exemplo de mercado no módulo.*

### **Relatório 17: Amazon Web Services. Benchmark de cache semântico do Amazon ElastiCache. Documentação oficial, 2025.**

Mediu, sobre 63.796 perguntas reais de chatbot e suas variantes parafraseadas (dataset SemBenchmarkLmArena), a relação entre limiar de similaridade e taxa de acerto/precisão/economia de custo - no limiar de 0,75, taxa de acerto de 90,3%, precisão de 91,2%, redução de custo de até 86% e de latência de até 88%.

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - documentação oficial de benchmark de cache semântico, referência técnica de mercado para o padrão apresentado no módulo.*

### **Relatório 18: FDA (Food and Drug Administration dos EUA). Guidance sobre uso de IA em decisões regulatórias de medicamentos. Janeiro de 2025.**

Propõe um framework de risco em sete passos, com categorias de influência baixa/alta e risco baixo/médio/alto; um algoritmo que decide sozinho, sem revisão humana, é influência alta e risco alto, enquanto revisão humana (ex.: teste de liberação por amostragem) reduz a influência do modelo e, com ela, o risco atribuído ao sistema.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - diretriz regulatória oficial da FDA sobre uso de IA em decisões regulatórias, base do Approval Gate do TrialForge.*

### **Relatório 19: FDA. 21 CFR Part 11.**

Norma que exige trilhas de auditoria seguras, geradas por computador, com timestamp, registrando de forma independente toda criação, modificação ou exclusão de registro eletrônico - não pode ser sobrescrita, só adicionada.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - norma regulatória citada como fundamento legal da trilha de auditoria e assinatura eletrônica do Approval Gate.*

## **Relatório 20: União Europeia. EU AI Act, Artigo 12.**

Exige que sistemas de IA de alto risco permitam tecnicamente o registro automático de eventos ao longo de toda a vida útil do sistema - o mesmo princípio do 21 CFR Part 11, como regulação geral de IA, não só de medicamento.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - norma regulatória europeia citada como fundamento legal de registro e rastreabilidade do Approval Gate.*

## **Relatório 21: LangGraph (LangChain). Documentação oficial, função interrupt().**

Mecanismo nativo de pausa de execução dentro de um grafo de agente: o estado inteiro é salvo e o fluxo espera, sem prazo definido, por uma entrada externa antes de continuar - usado para aprovação humana de uma chamada de API, mudança de banco de dados ou outra decisão importante.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - documentação oficial do mecanismo de pausa-e-retomada usado como referência técnica de implementação do Approval Gate.*

## **Relatório 22: AWS Bedrock Agents. Documentação oficial, mecanismo de confirmação de ação.**

Passo explícito de confirmação antes de executar uma ação proposta pelo agente: o sistema apresenta a ação e só executa se a resposta for CONFIRM, nunca DENY.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - documentação oficial do mecanismo equivalente de confirmação de ação, referência de mercado para o Approval Gate.*

## **Relatório 23: Stripe. Documentação oficial do Stripe Radar, avaliação de risco.**

Atribui a cada pagamento uma pontuação de risco de 0 a 99: acima de 65, fila de revisão manual; acima de 75, classificado como alto risco e bloqueado automaticamente por padrão nesse mesmo patamar.

*Relevância no curso: Módulo 4.4 (O Approval Gate) - documentação oficial de um sistema de decisão automatizada com escalonamento a revisor humano em produção, análogo de mercado ao Approval Gate.*

#### **Relatório 24: Google Cloud. Documentação de cold start para IA no Cloud Run. 2025.**

Documenta as quatro fases do cold start de um contêiner serverless com modelo de IA - provisionar (~5s), streaming da imagem (~1-2s), iniciar o motor (~5-15s) e carregar o modelo pra VRAM (maior gargalo) - com quantização de 4 bits como mitigação mais citada.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação oficial sobre o custo de cold start em cargas de IA, base técnica da decisão entre serverless e always-on discutida no módulo.*

#### **Relatório 25: Modal Labs. Documentação técnica sobre snapshot de memória de GPU. 2025.**

Reporta redução do tempo de boot de até 2000 segundos para cerca de 50 segundos (40x mais rápido) usando snapshot de memória de GPU, técnica que evita recarregar o modelo do zero a cada cold start.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação técnica sobre redução de cold start via snapshot de memória de GPU, referência de mercado para o mesmo problema discutido no módulo.*

#### **Relatório 26: Amazon Web Services. AWS Bedrock, modelo de precificação serverless.**

Documentação oficial declara que o serviço não exige nenhum gerenciamento de infraestrutura por parte do cliente, cobrando por token consumido.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação oficial do modelo de precificação serverless, referência para a análise de custo entre implantação híbrida e cloud pura do módulo.*

#### **Relatório 27: Cloudflare. Documentação técnica do Workers AI.**

Declara GPUs distribuídas em mais de 180 cidades ao redor do mundo, com 95% da população conectada à internet a menos de 50 milissegundos de distância de um data center Cloudflare.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação técnica de inferência distribuída na borda, exemplo de mercado de implantação híbrida discutido no módulo.*

#### **Relatório 28: Apple. Documentação técnica da Apple Intelligence e do Private Cloud Compute.**

Descreve um modelo de aproximadamente 3 bilhões de parâmetros rodando no próprio dispositivo, com quantização de 2 bits, escalando pra Private Cloud Compute em requisições

maiores - a Apple declara nunca guardar nem compartilhar esse dado, nem com a própria Apple.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação técnica do modelo híbrido on-device/nuvem privada da Apple, exemplo de mercado citado no módulo.*

### **Relatório 29: Google. Documentação técnica do Gemini Nano e do serviço AICore, Android.**

Declara que o modelo roda dentro do próprio sistema operacional, removendo a latência de rede - velocidade de inferência depende só do hardware do dispositivo - e funciona offline.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação técnica do modelo on-device do Android, segundo exemplo de mercado de implantação híbrida citado no módulo.*

### **Relatório 30: Kingfisher plc. Divulgação pública de arquitetura de dados e IA (dona de B&Q, Screwfix e Castorama).**

Documenta mais de 130 pipelines de treino e previsão de demanda rodando em Kubeflow sobre infraestrutura serverless, enquanto a inferência em produção roda em Kubernetes via GKE - e mede o ponto de virada de custo: computação serverless a cerca de US\$ 82,77 por vCPU-mês contra US\$ 39,73 num modelo convencional, cerca do dobro.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - divulgação pública de arquitetura de dados e IA em varejo, estudo de caso real de implantação híbrida em escala citado no módulo.*

### **Relatório 31: DigitalOcean. Documentação técnica sobre custo de GPU dedicada vs. serverless.**

Estabelece a regra prática de que, acima de 22-48% de utilização constante (dependendo da tolerância de latência), hospedar a própria GPU sai mais barato do que pagar por uso serverless.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação técnica de custo comparado de GPU dedicada vs. serverless, referência numérica usada na análise de custo do módulo.*

### **Relatório 32: LiteLLM (projeto aberto, uso interno relatado na Netflix); Cloudflare AI Gateway; Kong AI Gateway.**

Três produtos da mesma categoria - API Gateway unificado para múltiplos provedores de modelo, com cache, limite de taxa e failover embutidos. LiteLLM unifica mais de 100 provedores; Cloudflare e Kong oferecem a mesma categoria de funcionalidade sob o nome comercial "AI Gateway".

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - projetos reais de gateway de IA, um deles com uso relatado em produção na Netflix, referência de mercado para a camada de Gateway da arquitetura enterprise do módulo.*

**Relatório 33: KServe (CNCF, Incubating desde setembro de 2025); Kubeflow (Google, CNCF, anunciado em dezembro de 2017).**

KServe serve modelos já treinados em produção, com o campo `canaryTrafficPercent` permitindo rollout gradual e rollback instantâneo entre versões de modelo. Kubeflow, projeto irmão na CNCF, orquestra o pipeline de treino e experimentação - camada diferente do mesmo ciclo de vida, não concorrente.

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - projetos CNCF de orquestração de modelo em Kubernetes, referência de mercado para a camada de deploy/scaling da arquitetura enterprise do módulo.*

**Relatório 34: Sam Newman, "Building Microservices" (O'Reilly); Thomas Erl, "SOA: Principles of Service Design" (2008).**

Formalizam Loose Coupling e contratos explícitos entre serviços como pré-requisito de arquitetura distribuída - Erl nomeia esses princípios especificamente como Service Loose Coupling e Standardized Service Contract.

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - referências clássicas de arquitetura de microsserviços e SOA que fundamentam os princípios de modularidade aplicados à arquitetura enterprise do módulo.*

**Relatório 35: Open Policy Agent (OPA). Projeto CNCF, graduado em 29 de janeiro de 2021.**

Motor de política centralizada (policy-as-code) avaliada em tempo de execução, com casos de uso documentados para controlar acesso e limite de gateways de IA.

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - projeto CNCF graduado de governança-código, referência de mercado para a camada de políticas e segurança da arquitetura enterprise do módulo.*

**Relatório 36: Uber Engineering. "Navigating the LLM Landscape: Uber's Innovation with GenAI Gateway." Blog oficial, 11 de julho de 2024.**

O GenAI Gateway, construído pelo time Michelangelo (plataforma de ML interna da Uber), atende mais de 60 casos de uso distintos e cerca de 30 times internos, com 16 milhões de consultas por mês - espelhando o formato de API da OpenAI, com redação automática de PII nas requisições de saída, restaurada nas respostas de entrada.

*Relevância no curso: Módulo 5.1 (Arquitetura Enterprise) - relato técnico real de um gateway de IA em produção em escala, estudo de caso de mercado para a arquitetura enterprise do módulo.*

**Relatório 37: PromptLayer (versionamento de prompt); Langfuse (adquirido pela ClickHouse em janeiro de 2026); Arize Phoenix (OpenInference/OpenTelemetry, self-hosted).**

Três ferramentas de rastreamento de prompt em produção - versionamento tipo commit com diff e replay (PromptLayer), escala de mercado (Langfuse: mais de 23 milhões de instalações de SDK por mês, usado por 19 das 50 maiores empresas da Fortune 500), e opção self-hosted preferível para dado sensível (Arize Phoenix).

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - ferramentas reais de versionamento e observabilidade de prompt, referência de mercado para a prática de rastreamento de prompts do módulo.*

**Relatório 38: OpenTelemetry. GenAI Semantic Conventions. Padrão aberto, em desenvolvimento ativo.**

Nomeia campos padronizados de observabilidade específicos de IA generativa - tokens de entrada/saída, modelo exato usado, tempo até o primeiro token, documentos recuperados via RAG - permitindo que qualquer ferramenta de observabilidade leia o log de qualquer sistema de IA da mesma forma.

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - padrão aberto em desenvolvimento para telemetria de sistemas de IA, referência técnica para a instrumentação de observabilidade do módulo.*

**Relatório 39: Ewaschuk, R. "Monitoring Distributed Systems." Capítulo do livro Site Reliability Engineering, Google/O'Reilly.**

Formaliza os quatro sinais de ouro (golden signals) de observabilidade de sistemas distribuídos - Latência, Tráfego, Erros e Saturação.

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - capítulo clássico do livro Site Reliability Engineering do Google, fundamenta os princípios de monitoramento aplicados à observabilidade de sistemas de IA do módulo.*

**Relatório 40: DPD (Reino Unido). Incidente de chatbot manipulado, janeiro de 2024 (cobertura BBC, Fortune e outros).**

Um usuário (Ashley Beauchamp) induziu o chatbot de atendimento da DPD a xingar a própria empresa e escrever um poema criticando o serviço. A infraestrutura permaneceu tecnicamente saudável durante todo o incidente - nenhum dos quatro sinais clássicos de observabilidade capturaria essa falha de qualidade de conteúdo.

*Relevância no curso: Módulo 5.2 (Observabilidade em Escala) - incidente real de chatbot manipulado publicamente, caso de mercado usado para justificar a necessidade de observabilidade contínua discutida no módulo.*

#### **Relatório 41: Yuan, M. et al. "Large-scale Local Deployment of DeepSeek-R1 in Pilot Hospitals in China: A Nationwide Cross-sectional Survey." medRxiv, maio de 2025.**

Levantamento nacional documentando 261 hospitais chineses (93,5% das províncias do país) rodando o modelo DeepSeek-R1 localmente, sem chamada de API para nuvem de terceiros - 84% deles unidades terciárias, representando ainda só 0,7% do total de hospitais do país.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - estudo real de implantação local em larga escala de um modelo em hospitais, estudo de caso do setor regulado citado no módulo.*

#### **Relatório 42: Microsoft. Model Router (Azure AI Foundry / Microsoft Foundry); Amazon. Bedrock Intelligent Prompt Routing.**

Dois produtos reais de roteamento de modelo em cascata. O Model Router da Microsoft roteia entre famílias de modelo (incluindo Claude e Llama) com três modos - Balanceado (1-2% de diferença de qualidade), Custo (5-6%) e Qualidade (ignora custo). O Bedrock Intelligent Prompt Routing da Amazon aplica o mesmo princípio entre exatamente dois modelos da mesma família, com economia de custo de até 30%.

*Relevância no curso: Módulo 5.4 (Model Tiering) - produtos reais de roteamento de modelo em produção dos dois principais provedores de nuvem, confirmando que a cascata de model tiering do módulo já é prática de mercado.*

#### **Relatório 43: Anthropic. How We Built Our Multi-Agent Research System. Engineering blog, junho de 2025.**

Relato técnico interno mostrando que um sistema multi-agente (Claude Opus 4 líder + subagentes Sonnet 4 em paralelo) superou um agente único poderoso em 90,2% numa avaliação de pesquisa – ganho explicado majoritariamente pelo uso eficiente de tokens em paralelo, não por um modelo melhor. Custa cerca de 15 vezes mais tokens que um chat comum, e o consumo de tokens sozinho explica 80% da variância de performance observada.

*Relevância no curso: Módulo 3.1 (Por Que Múltiplos Agentes) - evidência real e recente do próprio criador do Claude sobre o ganho de performance e o custo real de coordenação de um sistema multiagente, mesmo trade-off discutido na abertura do módulo.*

#### **Relatório 44: Amazon Web Services. Multi-agent collaboration (Amazon Bedrock). Anunciado no re:Invent, dezembro de 2024; disponibilidade geral em março de 2025.**

Recurso nativo do Bedrock com dois modos nomeados literalmente “Supervisor” e “Supervisor com Roteamento” - o segundo usado quando o orquestrador só precisa direcionar a consulta pro agente especializado certo, sem sintetizar a resposta. A Syngenta usa esse recurso no Cropwise AI para ajudar produtores agrícolas a aumentar a produtividade da lavoura em até 5%.

*Relevância no curso: Módulo 3.2 (Sequential, Parallel e Supervisor) - implementação real de mercado do padrão Supervisor com Roteamento apresentado no módulo, incluindo um estudo de caso real com resultado numérico.*

### **Relatório 45: Anthropic. Prompt Caching with Claude. Agosto de 2024; OpenAI. Prompt Caching in the API. Outubro de 2024.**

Os dois principais fornecedores de modelo lançaram cache de prompt nativo na mesma janela de tempo - a Anthropic com redução de até 90% no custo e 85% na latência para prompts longos; a OpenAI com desconto automático de 50% em tokens já vistos anteriormente na mesma sessão, sem nenhuma configuração extra do desenvolvedor.

*Relevância no curso: Módulo 4.3 (Cache e Streaming) - lançamentos oficiais dos dois principais provedores de modelo confirmando que cache de prompt nativo já é prática padrão de mercado, complementar ao cache semântico apresentado no módulo.*

### **Relatório 46: Amazon Web Services. Architecting Distributed Agentic AI Workloads across AWS Hybrid Cloud Services. AWS Global Infrastructure and Sustainability Blog, 2025.**

Documenta que uma vantagem arquitetural chave de rodar agentes em infraestrutura híbrida é decompor a carga de trabalho e posicionar cada componente no tipo de instância mais adequado - GPU pra inferência de modelo grande, instâncias menores pra modelos pequenos rodando em Local Zones mais próximas do usuário.

*Relevância no curso: Módulo 5.3 (Implantação Híbrida) - documentação oficial da AWS citada diretamente no módulo pra fundamentar o princípio de decompor a carga de trabalho por componente na decisão de implantação híbrida.*

## **3. Indicações de Vídeo - YouTube**

---

Conteúdos audiovisuais gratuitos, de canais e eventos reconhecidos na área, recomendados como ponto de entrada complementar aos temas de cada módulo.

**Vídeo 1: "Beyond the Hype: Architecting Systems with Agentic AI." Painel com Tyler Jewell (AKKA), Arun Joseph (Masaic AI), Johannes Koch (FICO) e Merrin Kurian (Intuit). InfoQ Live, 2 de outubro de 2025.**

Canal: InfoQ Live - YouTube, 2 de outubro de 2025. Duração: ~1 hora.

Discussão sobre por que a maioria dos projetos empresariais de IA agêntica fica em protótipo, complexidade e não-determinismo, guardrails, e a mudança de "arquiteto de software" para "arquiteto de aprendizado".

*Relevância no curso: Módulo 1 (Fundamentos de Arquitetura AI-First) - contextualiza a crise de arquitetura discutida no M1.1.*

## **Vídeo 2: "How We Build Effective Agents." Barry Zhang, Anthropic. AI Engineer Summit, 2025.**

Canal: AI Engineer Summit - YouTube, 21 de fevereiro de 2025.

Explora padrões práticos de arquitetura de agente usados internamente pela Anthropic.

*Relevância no curso: Módulo 2 (Arquiteturas Single-Agent) - complementa os padrões ReAct, Reflexão e Tool-Using.*

## **Vídeo 3: "Armchair Architects: Multi-agent Orchestration and Patterns." Azure Essentials Show, Microsoft, janeiro de 2026.**

Canal: Azure Essentials Show, Microsoft - YouTube, janeiro de 2026.

Discussão sobre padrões de orquestração multiagente em ambiente corporativo.

*Relevância no curso: Módulo 3 (Arquiteturas Multi-Agent) - complementa Sequential, Parallel, Supervisor, Hierarchical, Group Chat e Handoff.*

## **Vídeo 4: "What is Retrieval-Augmented Generation (RAG)?" Marina Danilevsky, IBM Technology.**

Canal: IBM Technology - YouTube, 2023.

Explicação acessível de RAG e por que ele reduz alucinação e aumenta a confiabilidade da resposta de um modelo.

*Relevância no curso: Módulo 4.1 (RAG) - nivelamento conceitual.*

## **Vídeo 5: "Armchair Architects: Hybrid and Multi-Cloud Architectures - Observability." David Blank-Edelman e Uli Homann, Azure Essentials Show, Microsoft.**

Canal: Azure Essentials Show, Microsoft - YouTube.

Discussão sobre observabilidade em arquiteturas híbridas e multi-cloud.

*Relevância no curso: Módulo 5 (Arquitetura Enterprise) - complementa Observabilidade em Escala e Implantação Híbrida.*

Nota: papers disponíveis no arXiv são gratuitos em [arxiv.org](https://arxiv.org). Documentação técnica de provedores de nuvem está disponível gratuitamente em seus respectivos sites oficiais.

