



Processamento de Dados e Fine-Tuning de Modelos
Autoria: José Ahirton Batista Lopes Filho

Indicações de leitura

1. Referências Científicas e Acadêmicas

Artigos peer-reviewed e papers técnicos que fundamentam os métodos de fine-tuning, preparação de dados e avaliação ensinados na disciplina. Todos os artigos disponíveis no arXiv podem ser acessados gratuitamente em arxiv.org.

Indicação 1: [Hu, E. et al. \(Microsoft\). "LoRA: Low-Rank Adaptation of Large Language Models." arXiv:2106.09685, 2021.](#)

Paper que introduziu o LoRA: em vez de atualizar a matriz de pesos inteira, aprende duas matrizes de posto baixo que a aproximam, escaladas por α sobre r . Reduz drasticamente o número de parâmetros treináveis sem trocar a arquitetura do modelo.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - fundamenta a técnica central do Módulo 4, aplicada de verdade nos Módulos 4.2 a 4.4 com números reais de parâmetro treinável e memória.

Indicação 2: [Dettmers, T. et al. "QLoRA: Efficient Finetuning of Quantized LLMs." arXiv:2305.14314, NeurIPS 2023.](#)

Combina LoRA com quantização de 4-bit do modelo base, permitindo treinar um modelo de 65 bilhões de parâmetros numa única GPU de 48GB. O modelo resultante, Guanaco, chegou a 99,3% da performance do ChatGPT no benchmark Vicuna.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - um dos seis tipos de fine-tuning do cheatsheet da disciplina, com o case real do Guanaco.

Indicação 3: [Li, X.L.; Liang, P. "Prefix-Tuning: Optimizing Continuous Prompts for Generation." arXiv:2101.00190, ACL 2021.](#)

Uma das primeiras técnicas de PEFT (Parameter-Efficient Fine-Tuning): em vez de ajustar pesos do modelo, otimiza um pequeno prefixo contínuo prependado às ativações de atenção de cada camada do Transformer, mantendo o modelo base inteiramente congelado.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - citado na família de técnicas PEFT ao lado de LoRA, Prompt Tuning e Adapters.

Indicação 4: [Lester, B.; Al-Rfou, R.; Constant, N. "The Power of Scale for Parameter-Efficient Prompt Tuning." arXiv:2104.08691, EMNLP 2021.](#)

Mostra que, à medida que o modelo cresce para a casa dos bilhões de parâmetros, ajustar só um prompt contínuo aprendido por retropropagação fecha o gap de qualidade contra o ajuste completo do modelo.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - segunda técnica citada na família PEFT.

Indicação 5: Houlsby, N. et al. "Parameter-Efficient Transfer Learning for NLP." arXiv:1902.00751, ICML 2019.

Introduziu os módulos adapter: pequenas camadas inseridas dentro de cada bloco do transformer, mantendo o resto do modelo congelado. Chegou a 0,4% da performance do fine-tuning completo usando só 3,6% dos parâmetros por tarefa.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - terceira técnica citada na família PEFT, anterior ao LoRA.

Indicação 6: Wei, J. et al. (Google). "Finetuned Language Models Are Zero-Shot Learners." arXiv:2109.01652, 2021.

Introduziu o FLAN, um modelo de 137 bilhões de parâmetros ajustado por instrução em mais de 60 tarefas, que superou o GPT-3 de 175 bilhões em 20 de 25 tarefas nunca vistas no treino.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - caso real de Instruction Tuning no cheatsheet dos seis tipos de fine-tuning.

Indicação 7: Ouyang, L. et al. (OpenAI). "Training Language Models to Follow Instructions with Human Feedback." arXiv:2203.02155, 2022.

O paper do InstructGPT: um modelo de 1,3 bilhão de parâmetros ajustado por RLHF foi preferido ao GPT-3 de 175 bilhões pelos avaliadores humanos, apesar de ter cem vezes menos parâmetros.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - caso real de RLHF/DPO no cheatsheet.

Indicação 8: DeepSeek-AI. "DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning." arXiv:2501.12948, 2025.

Relatório técnico do DeepSeek-R1, incluindo a destilação de 800 mil exemplos de treinamento supervisionado (cerca de 600 mil de raciocínio, 200 mil não relacionados a raciocínio) gerados pelo modelo de 671 bilhões de parâmetros em modelos densos bem menores, de 1,5 a 70 bilhões.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - caso real de Distillation no cheatsheet, também citado no Fine-Tuning Zoo, o companion visual do Módulo 1.

Indicação 9: Chen, M. et al. (OpenAI). "Evaluating Large Language Models Trained on Code." arXiv:2107.03374, 2021.

Descreve o Codex, um GPT-3 com fine-tune completo em 159GB de código do GitHub, que virou a base do GitHub Copilot. No benchmark HumanEval, resolveu 28,8% dos problemas contra 0% do GPT-3 original.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - caso real de Full Fine-Tuning no cheatsheet.

Indicação 10: Zhou, C. et al. (Meta, CMU, USC, Tel Aviv). "LIMA: Less Is More for Alignment." arXiv:2305.11206, NeurIPS 2023.

Treinou um modelo de 65 bilhões de parâmetros com só 1.000 exemplos cuidadosamente curados, sem RLHF, e obteve qualidade competitiva com modelos ajustados em dezenas de milhares de exemplos.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - fundamenta o gate de relevância de dado e o princípio Data-Centric AI, priorizando qualidade sobre volume.

Indicação 11: Lee, K. et al. (Google Research). "Deduplicating Training Data Makes Language Models Better." arXiv:2107.06499, ACL 2022.

Mediu o efeito real de deduplicar o corpus de treino de um modelo de linguagem: no corpus C4, encontrou uma única frase de 61 palavras repetida mais de 60 mil vezes. Deduplicar reduz texto memorizado em cerca de 10 vezes.

Relevância no curso: Módulo 2.2 (Preparação de Datasets para Fine-Tuning) - fundamenta por que deduplicação não é faxina cosmética, é parte central do pipeline de dataset.

Indicação 12: Broder, A. "On the Resemblance and Containment of Documents." Proceedings of Compression and Complexity of Sequences (SEQUENCES), IEEE, 1997.

Paper original do MinHash: transforma cada documento numa assinatura de números fixos, cuja fração de posições iguais entre duas assinaturas estima a similaridade de Jaccard real sem nunca comparar o conteúdo completo.

Relevância no curso: Módulo 2.2 (Preparação de Datasets para Fine-Tuning) - fundamenta a técnica MinHash + LSH usada na deduplicação do dataset.

Indicação 13: Raffel, C. et al. "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer." arXiv:1910.10683, JMLR 2020.

Paper do T5, que também formaliza o esquema de amostragem por temperatura usado pra balancear a proporção de dado entre fontes diferentes durante o pré-treino.

Relevância no curso: Módulo 2.2 (Preparação de Datasets para Fine-Tuning) - fundamenta a fórmula de amostragem por temperatura usada pra balancear as fontes do dataset.

Indicação 14: Xue, L. et al. "mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer." arXiv:2010.11934, NAACL 2021.

Extensão multilíngue do T5, treinada em 101 idiomas. Usa alpha igual a 0,3 na amostragem por temperatura pra balancear idiomas de alto e baixo recurso, o mesmo valor usado no pipeline de balanceamento desta disciplina.

Relevância no curso: Módulo 2.2 (Preparação de Datasets para Fine-Tuning) - fonte do valor exato de alpha (0,3) usado no balanceamento por temperatura do dataset.

Indicação 15: Hill, M.O. "Diversity and Evenness: A Unifying Notation and Its Consequences." Ecology, 1973; Jost, L. "Entropy and Diversity." Oikos, 2006.

Formalizam o número efetivo de espécies (Hill number), depois generalizado como número efetivo de fontes: exp da entropia de Shannon, que traduz uma distribuição desigual pra "quantas fontes igualmente representadas isso equivale".

Relevância no curso: Módulo 2.2 (Preparação de Datasets para Fine-Tuning) - fundamenta a métrica de número efetivo de fontes usada pra medir diversidade do dataset antes e depois do balanceamento.

Indicação 16: Saaty, T.L. "The Analytic Hierarchy Process." McGraw-Hill, 1980.

Livro que formaliza o AHP: deriva pesos de critérios a partir de uma matriz de comparação pareada, com uma Razão de Consistência que testa se o julgamento humano por trás dos pesos é internamente coerente.

Relevância no curso: Módulo 1.2 (Quando Fazer Fine-Tuning) - método usado pra derivar os pesos das quatro perguntas do framework de decisão de fine-tuning.

Indicação 17: Halevy, A.; Norvig, P.; Pereira, F. (Google). "The Unreasonable Effectiveness of Data." IEEE Intelligent Systems, 2009.

Artigo de pesquisadores do Google argumentando que, em muitos problemas práticos, mais dado supera arquitetura mais sofisticada, a chamada "eficácia desproporcional dos dados" (unreasonable effectiveness of data), mesmo quando parte desse dado vem de um domínio diferente do problema-alvo.

Relevância no curso: Módulo 5.2 (Avaliar Modelos Fine-Tunados, PT-2) - citado pra explicar por que o job de fine-tuning conjunto (200 exemplos, dois domínios) bateu os jobs separados por domínio (80 e 120 exemplos): o que importou pro resultado foi o volume total de treino, não a pureza de cada domínio isolado.

Indicação 18: Ovadia, O. et al. (Microsoft). "Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs." arXiv:2312.05934, EMNLP 2024.

Estudo controlado comparando fine-tuning não supervisionado contra RAG pra injetar conhecimento novo em três modelos (Mistral-7B, Llama2-7B, Orca2-7B). RAG supera fine-tuning de forma consistente, tanto pra conhecimento já visto no treino quanto pra fatos totalmente novos; num dos modelos, fine-tuning sozinho chegou a piorar a acurácia.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - reforça com evidência controlada e peer-reviewed o mito derrubado no Slide 4: fine-tuning não é a ferramenta certa pra injetar conhecimento novo, RAG é.

Indicação 19: Liu, S.-Y. et al. (NVIDIA). "DoRA: Weight-Decomposed Low-Rank Adaptation." arXiv:2402.09353, ICML 2024.

Decompõe a atualização de peso do LoRA em duas componentes, magnitude e direção, em vez de só direção como o LoRA original; a literatura de 2026 trata DoRA como sucessor natural do LoRA em várias aplicações.

Relevância no curso: Módulo 4.3 (Trade-offs Desempenho vs. Eficiência de Parametrização) - base da variante DoRA testada de verdade contra o LoRA rank oito do Módulo 4.2: resultado honesto de empate dentro da faixa de ruído, não confirma ganho universal em treino pequeno.

Indicação 20: Bai, Y. et al. (Anthropic). "Constitutional AI: Harmlessness from AI Feedback." arXiv:2212.08073, 2022.

Em vez de rótulo humano em cada par de preferência, o próprio modelo se autocritica e revisa a resposta contra um conjunto escrito de princípios (a "constituição"), reduzindo a dependência de anotação humana no pipeline de alinhamento.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - base da variante RLAIIF/Constitutional AI documentada como nota adicional no cheatsheet, junto da técnica de RLHF/DPO.

Indicação 21: Lee, H. et al. (Google DeepMind). "RLAIF vs. RLHF: Scaling Reinforcement Learning from Human Feedback with AI Feedback." arXiv:2309.00267, 2023.

Mede o custo real de rotulagem de preferência: US\$ 0,06 por exemplo via feedback de IA contra US\$ 0,67 por exemplo via rotulagem humana, mais de dez vezes mais barato, mantendo qualidade de alinhamento comparável.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - fonte do número real usado na nota RLAIF do cheatsheet, corrigindo internamente uma estimativa inicial de “~100x” pro valor efetivamente medido (~11x).

Indicação 22: Shao, Z. et al. (DeepSeek-AI). “DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models.” arXiv:2402.03300, 2024.

Introduz o GRPO (Group Relative Policy Optimization): estima a vantagem de cada resposta a partir da média e do desvio-padrão de recompensa de um grupo de amostras da mesma pergunta, eliminando a necessidade de um modelo crítico separado.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - mecanismo por trás da sétima espécie do cheatsheet (GRPO/RFT) e do demo rodável de recompensa verificável, reproduzido contra o caso Amplitude Seguros.

Indicação 23: Yu, Q. et al. (ByteDance, Tsinghua). “DAPO: An Open-Source LLM Reinforcement Learning System at Scale.” arXiv:2503.14476, 2025.

Documenta e nomeia o fenômeno do “grupo degenerado”: quando todas as amostras de um grupo recebem a mesma recompensa, o desvio-padrão zera e a vantagem de todo o grupo vai a zero, sem sinal de treino útil.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - explica o resultado real reproduzido no demo GRPO desta disciplina: os seis candidatos amostrados receberam a mesma recompensa (0,83), um grupo degenerado de verdade, não simulado.

Indicação 24: Google DeepMind. “Gemini 2.5: Pushing the Frontier with Advanced Reasoning, Multimodality, Long Context, and Next Generation Agentic Capabilities.” arXiv:2507.06261, 2025.

Relatório técnico do Gemini 2.5 cita “recompensas generativas baseadas em modelo” no pipeline de alinhamento, inspiradas na linha de trabalho de Constitutional AI, ainda que sem usar o nome RLAIF explicitamente.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - evidência de que a técnica de auto-crítica/recompensa gerada por modelo já está em produção num modelo de fronteira, não só em papers de pesquisa.

Indicação 25: Becker, K. et al. "Deidentifying Medical Documents with Local, Privacy-Preserving Large Language Models: The LLM-Anonymizer." NEJM AI, DOI: 10.1056/Aldbp2400537, 2025.

Testa um Llama-3 70B local, via llama.cpp, contra 250 cartas clínicas reais em alemão: 99,24% dos caracteres de PHI corretamente redigidos, 0,76% perdidos, 2,43% de falso positivo, número real, revisado por pares, no nível de caractere.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - caso real verificado citado no companion de fine-tuning com dado regulado, sustenta a recomendação de higienizar PII localmente antes do treino.

2. Referências de Mercado e Relatórios da Indústria

Casos reais de empresas, documentação oficial de provedores e normas regulatórias citados ao longo do curso, sempre com fonte verificável.

Relatório 1: OpenAI. "Indeed builds an AI-powered virtual recruiter with OpenAI." openai.com/index/indeed.

Case oficial da OpenAI: a Indeed fine-tunou um modelo GPT menor pra manter a qualidade das recomendações de vaga, usando 60% menos tokens que few-shot prompting na mesma tarefa, na escala deles.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - exemplo de fine-tuning aplicado certo: tarefa estreita e repetida, ganho real de custo.

Relatório 2: Kadous, W.; Hakhamaneshi, K. "Fine Tuning Is For Form, Not Facts." Anyscale, 5 de julho de 2023.

Relato real: a Anyscale fine-tunou um modelo de 6 bilhões de parâmetros no texto de Romeu e Julieta com o nome Romeo substituído por Bob. Perguntado quem era o amado de Julieta, cujo nome começava com R, o modelo continuou respondendo Romeo: o fine-tuning não gravou o fato novo de forma confiável.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - exemplo de fine-tuning aplicado errado: tratar um problema de conhecimento, que muda, como se fosse de comportamento.

Relatório 3: Predibase. "Fine-Tuned SLMs Help Checkr Optimize Background Checks." predibase.com/blog.

A Checkr fine-tunou um Llama-3-8B com LoRA pra classificar registros de verificação de antecedentes, chegando a 90% de acurácia nos casos mais difíceis, 5x mais barato e 30x mais rápido que a solução anterior com GPT-4.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) e Módulo 4.1 (LoRA e PEFT) - caso real de LoRA citado nos dois módulos.

Relatório 4: OpenAI. "Customizing models for legal professionals" (Harvey). openai.com/index/harvey.

Em 2023, a Harvey fine-tunou um modelo jurídico customizado com a OpenAI; em comparação lado a lado, advogados preferiram o modelo fine-tunado ao GPT-4 em 97% dos casos.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - primeira metade do caso Harvey, sobre risco de obsolescência do fine-tuning.

Relatório 5: Harvey. "Expanding Harvey's Model Offerings." harvey.ai/blog, 13 de maio de 2025.

Em 2025, a Harvey testou o mesmo modelo fine-tunado de 2023 contra os modelos de fronteira mais recentes: sete deles, sem nenhum fine-tuning jurídico, já haviam superado o modelo customizado.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - segunda metade do caso Harvey, mostrando que a decisão de fine-tuning não é permanente.

Relatório 6: Applied Compute. Case study Harvey. appliedcompute.com/case-studies/harvey.

Em 2026, a Harvey re-treinou (modelo GLM-5.1) e recuperou a liderança no próprio benchmark jurídico, superando GPT-5.5 e Opus 4.8 Max, com pipeline de avaliação 5x mais barato que o da OpenAI.

Relevância no curso: Módulo 1.3 (Quando Fazer Fine-Tuning) - fecha o arco do caso Harvey: reavaliar periodicamente faz parte do processo, não é exceção.

Relatório 7: OpenAI. "Introducing Structured Outputs in the API." openai.com, agosto de 2024.

A própria OpenAI aplica em produto a lógica de escalar de prompt engineering pra uma solução mais estruturada só quando necessário: o recurso garante que a saída do modelo bata exatamente com um schema JSON fornecido pelo desenvolvedor, sem fine-tuning.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - citado como exemplo de produto real que resolve parte do problema de formato estruturado sem fine-tuning.

Relatório 8: Jaffer, M. (Product Lead, OpenAI). Citado em Gupta, A. "RAG vs. Fine-tuning vs. Prompt Engineering: The Complete Guide to AI Optimization." news.aakashg.com, 2025.

Resume a ordem certa de escalar entre as três técnicas: comece com prompt engineering (horas ou dias), suba pra RAG quando precisar de dado que muda, e só considere fine-tuning quando as duas primeiras já foram tentadas de verdade.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - citado na narração como resumo da ordem de escalada entre as três técnicas.

Relatório 9: OpenAI. API deprecations (fine-tuning self-serve). developers.openai.com/api/docs/deprecations.

Documentação oficial do cronograma de descontinuação do fine-tuning self-serve da OpenAI: orgs novas já bloqueadas desde maio de 2026, acesso encerrado por inatividade desde julho de 2026, desligamento total em janeiro de 2027.

Relevância no curso: Módulos 1.3 e 3.1 - fundamenta a correção de mercado que abre o Módulo 3: por que o provedor real desta disciplina é a Vertex AI, não OpenAI self-serve.

Relatório 10: Google. Documentação de model tuning da Gemini API. ai.google.dev/gemini-api/docs/model-tuning.

Documentação oficial confirmando que o fine-tuning público da Gemini API foi descontinuado desde maio de 2025, com o Gemini 1.5 Flash-001 como último modelo suportado.

Relevância no curso: Módulos 1.3 e 3.1 - segunda metade da correção de mercado sobre provedores de fine-tuning self-serve.

Relatório 11: Hugging Face. Biblioteca PEFT (Parameter-Efficient Fine-Tuning). github.com/huggingface/peft.

Biblioteca open source que reúne LoRA, QLoRA, Prefix Tuning, Prompt Tuning e Adapters numa interface só, hoje o ponto de entrada padrão de mercado pra qualquer uma dessas técnicas.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - biblioteca de referência citada ao fechar a família de técnicas PEFT.

Relatório 12: Tesseract OCR. Projeto open source. github.com/tesseract-ocr/tesseract.

Motor de OCR com origem na HP nos anos 1980-90, aberto como projeto open source em 2005 e patrocinado pelo Google por mais de uma década. É o motor real usado pra extrair texto dos documentos crus da Amplitude Seguros.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - ferramenta real usada no pipeline de extração de documento pra JSONL.

Relatório 13: Brasil. Lei Geral de Proteção de Dados Pessoais (LGPD), Lei nº 13.709/2018, Art. 5º, II; Art. 7º; Art. 11.

Base legal do gate de governança do framework de decisão: define categoria de dado sensível (Art. 5º, II), as hipóteses que autorizam o tratamento de dado comum (Art. 7º) e as hipóteses específicas pra dado sensível de saúde (Art. 11).

Relevância no curso: Módulo 1.2 (Quando Fazer Fine-Tuning) - fundamenta o gate binário de governança, aplicado antes do AHP em todos os casos.

Relatório 14: Google. "About supervised fine-tuning for Gemini models." docs.cloud.google.com/gemini-enterprise-agent-platform, 2026.

Documentação oficial da Google sobre fine-tuning supervisionado de modelos Gemini na Gemini Enterprise Agent Platform, a evolução do Vertex AI anunciada em abril de 2026. Modelos atualmente suportados pra supervised tuning: gemini-2.5-pro, gemini-2.5-flash e gemini-2.5-flash-lite; modalidades cobertas incluem texto, documento, imagem, áudio, vídeo e function-calling.

Relevância no curso: Módulos 3 a 6 (Fine-Tuning via API e Projeto Final) - documentação oficial do provedor real usado do Módulo 3 em diante nesta disciplina.

Relatório 15: Google DeepMind / Google Research. "VaultGemma: The World's Most Capable Differentially Private LLM." 2025.

Primeiro LLM de escala de produção (1 bilhão de parâmetros) treinado do zero com DP-SGD (privacidade diferencial), demonstrando que a técnica deixou de ser viável só em modelo pequeno de laboratório.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - caso real citado no companion de fine-tuning com dado regulado, referência de escala pra privacidade diferencial em produção.

Relatório 16: Autoridade Nacional de Proteção de Dados (ANPD). Nota Técnica nº 12/2025 e Agenda Regulatória 2026-2027.

Trata privacidade diferencial e anonimização como mitigação obrigatória de RIPD (Relatório de Impacto à Proteção de Dados) em projeto de IA, não como boa prática opcional; nomeia sistema de IA que processa dado sensível como um dos quatro eixos prioritários de fiscalização 2026-2027.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - fundamenta o ângulo regulatório brasileiro do companion de fine-tuning com dado regulado, conecta ao gate de governança do Módulo 1.2.

Relatório 17: Microsoft. Documentação do Presidio (microsoft.github.io/presidio).

Ferramenta open source de referência de mercado pra detecção e anonimização de PII, combinando regex pra identificador estruturado de alta confiança com NER via spaCy pra nome em texto livre, cerca de 13 tipos de entidade global suportados.

Relevância no curso: Módulo 2.1 (Preparação de Datasets para Fine-Tuning) - abordagem híbrida (regex + NER) usada como referência de desenho pro gate real de higienização de PII construído nesta disciplina.

Relatório 18: EXL Service Holdings; NVIDIA. “EXL launches specialized Insurance LLM leveraging NVIDIA AI Enterprise.” EXL Newsroom, 26 de setembro de 2024; confirmado por CIO.com, 5 de fevereiro de 2025.

A EXL (BPO/analytics pra seguradora, Nasdaq: EXLS) construiu um LLM fine-tunado sobre vinte e cinco anos de dado proprietário de sinistro, via SFT + LoRA em NVIDIA NeMo, pra leitura, extração e apoio a underwriting. Resultado: 30% de melhoria de acurácia frente a LLM genérico de ponta, com 30% menos custo operacional.

Relevância no curso: Módulo 6.1 (Projeto Final) - case real citado no vídeo pra reforçar que o mesmo par de domínios simulado pela Amplitude Seguros já roda em produção de verdade.

Relatório 19: Nubank. “Your Spending Needs Attention: Modeling Financial Habits with Transformers.” arXiv:2507.23267, julho de 2025 (v2 agosto de 2026).

A Nubank treinou um transformer causal do zero sobre sequência bruta de transação bancária, não feature tabular manual, depois fine-tuning pra tarefas de negócio como default de crédito e risco de empréstimo, em produção pra mais de 100 milhões de clientes. Resultado: +1,25% de AUC relativo sobre o baseline de produção, que a própria empresa descreve como 3x o ganho tipicamente observado num modelo com impacto de negócio relevante.

Relevância no curso: Módulo 6.1 (Projeto Final) - case real citado no vídeo, mostrando que o mesmo princípio (dado proprietário + fine-tuning bate modelo genérico) se replica fora do domínio de texto.

Relatório 20: Intercom. “Announcing Fin Apex: The age of vertical models is here.” The Intercom Blog, 26 de março de 2026.

A Intercom treinou um modelo pós-treinado (RL ancorado em outcome real) especificamente pra resolução de ticket de suporte, sobre bilhões de interação humano-agente real. Resultado: 73,1% de taxa de resolução autônoma, superando GPT-5.4, Claude Opus 4.5 e Claude Sonnet 4.6 no benchmark da própria empresa, resolvendo cerca de 2 milhões de conversas por semana.

Relevância no curso: Módulo 6.3 (Projeto Final) - case real citado no fechamento do vídeo, validando em produção o argumento central do capstone: dado proprietário bate modelo genérico maior.

Relatório 21: Fortune. “AI coding tool Replit wiped a company’s production database and called it ‘a catastrophic failure.’” fortune.com, 23 de julho de 2025.

O agente de codificação da Replit apagou um banco de dados de produção inteiro durante um code freeze explícito, e inicialmente informou que a recuperação era impossível, o que era falso. O CEO Amjad Masad confirmou o incidente publicamente e anunciou mudanças de produto: separação obrigatória entre ambiente de desenvolvimento e produção, modo só-leitura por padrão.

Relevância no curso: Módulo 6.2 (Projeto Final) - caso real citado no vídeo como contraponto ao design de recusa do protótipo: nunca inventar resposta quando não há certeza.

Relatório 22: Hugging Face. “Anatomy of a Frontier Lab Agent Intrusion: A Technical Timeline of the July 2026 Incident.” huggingface.co/blog, 27 de julho de 2026.

Reconstrução forense oficial: dois modelos da OpenAI, testando capacidade cibernética num ambiente de sandbox com guardrails propositalmente relaxados, escaparam do isolamento explorando uma falha de dia zero, e comprometeram infraestrutura de produção real da Hugging Face, cerca de 17.600 ações registradas entre 9 e 13 de julho de 2026.

Relevância no curso: Módulo 6.3 (Projeto Final) - incidente real citado no fechamento do vídeo, motivando por que a próxima disciplina do programa (Segurança e Governança em IA) trata agente autônomo como risco real, não hipotético.

Relatório 23: Hassabis, D. (CEO, Google DeepMind). “A Framework for Frontier AI and the Dawning of a New Age.” Substack (demishassabis.substack.com), 14 de julho de 2026.

Ensaio pessoal do CEO da Google DeepMind: define AGI como sistema que exhibe todas as capacidades cognitivas do cérebro humano, estima que está “a só alguns poucos anos de distância”, e propõe um órgão internacional de padrões, no modelo da FINRA, pra governar IA de fronteira antes da chegada dela.

Relevância no curso: Módulo 6.3 (Projeto Final) - citado no segmento de fechamento sobre o futuro da IA, junto com a tese de world models de Hassabis (Genie 3) como caminho pra AGI.

3. Indicações de Vídeo - YouTube

Conteúdo audiovisual gratuito, de canais reconhecidos na área, recomendado como ponto de entrada complementar aos temas técnicos do curso.

Vídeo 1: "Is Fine-Tuning Still Needed? LLMs, RAG, & LoRA." IBM Technology - YouTube.

Canal: IBM Technology - YouTube.

Martin Keen (IBM Technology) discute se fine-tuning ainda vale a pena diante de modelos de fronteira com janela de contexto maior, raciocínio estendido e inferência mais barata, cobrindo RAG vs. fine-tuning vs. LoRA como decisão prática.

Relevância no curso: Módulo 1.1 (Quando Fazer Fine-Tuning) - mesma pergunta central do módulo, RAG vs. fine-tuning vs. LoRA como decisão; complementa o adendo sobre capacidade de fronteira em ascensão.

Vídeo 2: Raschka, S. "Finetuning LLMs for Classification." YouTube, abril de 2025.

Canal: Sebastian Raschka - YouTube.

Tutorial com 19 experimentos testando variações de fine-tuning (incluindo LoRA vs. full fine-tuning) para converter um LLM decoder-only num classificador, incluindo o efeito de qual token usar no treino e de qual camada do transformer ajustar.

Relevância no curso: Módulo 4.1 (LoRA e PEFT) - complementa a comparação LoRA vs. full fine-tuning com dados experimentais próprios do autor, que também escreveu o livro-base de referência da área.

Nota: só foram incluídos neste bloco vídeos com canal, título e conteúdo verificáveis de forma independente. Outros candidatos pesquisados não tinham procedência confirmável o bastante pra entrar numa lista de leitura oficial.

Nota: papers disponíveis no arXiv são gratuitos em arxiv.org. Documentação técnica de provedores de nuvem e bibliotecas open source está disponível gratuitamente em seus respectivos sites oficiais. O texto da LGPD está disponível gratuitamente em planalto.gov.br.

